Klasifikasi Risiko Penyakit Jantung

Sebuah institusi kesehatan kardiologi ingin membangun sistem kecerdasan buatan berbasis *Machine Learning* untuk mendeteksi dan memprediksi tingkat risiko pasien mengalami penyakit jantung koroner (*Coronary Heart Disease / CHD*) dalam kurun waktu 10 tahun ke depan secara otomatis, berdasarkan rekam medis klinis pasien tanpa harus melalui estimasi manual yang kompleks.

Dataset ini merekam berbagai fitur faktor risiko kesehatan dari ribuan pasien, di mana setiap sampel direpresentasikan oleh 15 fitur klinis dan demografis. Tim analis bertugas membangun model *machine learning* berbasis **Logistic Regression** untuk memprediksi label target biner (TenYearCHD: 0 atau 1) berdasarkan riwayat tekanan darah, kadar kolesterol, kebiasaan merokok, usia, dan indeks massa tubuh yang terkandung di dalam tiap baris data.

Penjelasan Struktur Dataset (framingham.csv):

- **Ukuran Data:** 4238 baris (mewakili 4238 sampel pasien) dan 16 kolom.
- **Fitur Input (X):** 15 kolom atribut klinis dan gaya hidup pasien, yang meliputi:
    - male: Jenis kelamin pasien (Kategori biner: 1 untuk pria, 0 untuk wanita).
    - age: Usia pasien (satuan: Tahun).
    - education: Tingkat pendidikan pasien (Kategori integer: 1 sampai 4).
    - currentSmoker: Status perokok aktif (Kategori biner: 1 ya, 0 tidak).
    - cigsPerDay: Jumlah rokok yang dihisap per hari (satuan: Batang rokok).
    - BPMeds: Penggunaan obat tekanan darah (Kategori biner: 1 ya, 0 tidak).
    - prevalentStroke: Riwayat stroke sebelumnya (Kategori biner: 1 ya, 0 tidak).
    - prevalentHyp: Riwayat hipertensi (Kategori biner: 1 ya, 0 tidak).
    - diabetes: Riwayat penyakit diabetes (Kategori biner: 1 ya, 0 tidak).
    - totChol: Kadar kolesterol total (satuan: mg/dL).
    - sysBP: Tekanan darah sistolik (satuan: mmHg)
    - diaBP: Tekanan darah diastolik (satuan: mmHg)
    - BMI: Indeks Massa Tubuh / *Body Mass Index* (satuan: kg/m^2).
    - heartRate: Denyut jantung (satuan: Detak per menit / bpm).
    - glucose: Kadar glukosa darah (satuan: mg/dL).
- **Target Label (Y):** Kolom TenYearCHD di bagian akhir yang berisi nilai biner (0 = Tidak berisiko terkena CHD dalam 10 tahun, 1 = Berisiko terkena CHD dalam 10 tahun).

Tahapan Pengerjaan:

- Business Understanding
- Data Preparation
- Exploratory Data Analysis

- Data Preprocessing
- Modelling (menggunakan algoritma *Logistic Regression*)
- Evaluation
- GUI